我们离原生自回归视频模型还有多远

Weiyang Jin，香港大学 · 2026年8月31日

语言模型里，自回归的意思其实早就清楚了。预训练拟合的就是

$$p(w_{1:n}) = \prod_i p(w_i \mid w_{<i}),$$

每写下一个词只需一次前向，训练看见的、测试看见的，都是已经写出的词。没人会先训一个双向 BERT [6]，再蒸馏出一个「看起来像 GPT」的学生，然后说这就是原生自回归。推理时加一层因果 mask，同样不算。

视频如果也用这个词，对 $V = (v_1, \dots, v_T)$，就写成

$$p(V \mid c) = \prod_t p(v_t \mid v_{<t}, c_{\le t}).$$

c_t 是当时已经有的条件：文本、第一帧、相机位姿、按键。它可以进条件，但不等于可以去看还没发生的 $v_{>t}$。这里说的原生自回归有两层意思，预训练拟合的就是这个乘积，写出下一步只需一次前向。Echo-WM-Flash [1] 是我们按现在通行的扩散自回归训过的模型之一，下面讲这套做法离这个定义还有多远。

图像没有时间；视频多出来的是 t

一张图里，左右是同时存在的。PixelRNN [4] 把似然写成光栅顺序 $p(x) = \prod_{h,w} p(x_{hw} \mid x_{<hw})$，只是给联合分布排个序，这个序是编码约定，不是时间。DiT [12] 后来把光栅顺序丢掉，在 (h, w) 上做双向注意力，更接近一张照片，帧内空间双向没问题。

视频多出来的是 t。Video Pixel Networks [5] 在像素级就已经把 t 当序列，而不是把时长 T 拉成一张更高的图。写 v_t 的时候，下一帧还没发生，不是画面还没画完。所以同一个似然里，两种顺序不是一类东西：

$$p(V) = \prod_t p\big(v_t \mid v_{<t}\big), \qquad p(v_t \mid v_{<t}) \text{ 在 } (h, w) \text{ 上可以双向。}$$

时间上的这个乘积，是因为后面的帧这一刻还不存在；帧内双向只是当前帧怎么表示。把 T 当成更长的 H，就是把「还没发生」当成「画面另一边还没画完」。短短几秒的片子上，这个差别几乎看不出来，未来帧就在同一条训练样本里，用上它们画质更好，Sora [14]、Wan [16]、LTX [15] 靠的就是这个。它们拟合的是整段短片的联合分布，所以每个时刻的条件是

$$q_{\text{bi}}(v_t \mid V_{\setminus t}, c).$$

测试变成流式生成以后，需要的条件就变了。接着往下写，中途会碰到新的 c_t，生成也会比训练见过的窗口更长。这时要拟合的是

$$q_{\text{AR}}(v_t \mid v_{<t}, c_{\le t}) = p_{\text{data}}(v_t \mid v_{<t}, c_{\le t}).$$



短片训练里写第 5 帧，1–8 都可以进条件。



流式生成只看见已经发生的。写第 5 帧时，6–8 还不存在。

训练时能看见哪些变量，学到的条件就不一样。c_t 换成文本、图像或位姿，只是条件里多一项，$V_{\setminus t}$ 不会变成 $v_{<t}$。世界模型 [22–25] 很早就把这个错位露出来了，因为人一边看一边操作。更长的视频、更低延迟的续写，碰到的还是这件事。

VideoGPT [7]、TATS [9] 已经在离散符号上写过 $\prod_t p(v_t \mid v_{<t})$。画质后来不如 MaskGIT [8]、MAGVIT [11]、Phenaki [10]，再不如按整段短片训的 DiT 级双向模型。图好看了，「下一帧只看过去」却丢掉了。测试变成流式

生成之后，领域没有回到「时间上只看过去」的预训练，问的是已经训好的 q_{bi} 怎么改一改，让测试看起来像 q_{AR}，后面的流水线一直在做这件事。

训练看见了未来，生成下一步也不止一次前向

按这个定义，现在通行的扩散自回归这两条都不成立。

先说训练。训练时本该拟合 $q_{\text{train}}(v_t \mid \cdot) = p_{\text{data}}(v_t \mid v_{<t})$。如果拟合的是 q_{bi}，推理时再加因果 mask（当前块不许看后面的块），只是测试时挡住训练用过的未来。模型从来没有在「只有过去」这个条件下训练过。

再说生成。时间切成 $B_1, \dots, B_N$ 之后，写成 $p(B_{1:N}) = \prod_i p_\theta(B_i \mid B_{<i})$。可这一步如果做成

$$x_{\sigma_K} \sim \mathcal{N}(0, I), \quad x_{\sigma_k} = x_{\sigma_{k+1}} + (\sigma_k - \sigma_{k+1})\, v_\theta(x_{\sigma_{k+1}}, \sigma_{k+1} \mid B_{<i}, B_i^{\text{noisy}}),$$

写出来的并不是直接的 B_i，而是一段常微分方程积出来的。$K \sim 30$ 是短片双向模型的积分长度；$K = 4$ 只是把同一种向量场的步数缩短，并不是一次前向写出 $f_\theta(v_{<t})$。

这两条缺口接着会变成一串后训练。训练已经看见未来，推理就只能加上因果 mask，训练时历史用的是干净数据（teacher forcing），测试时历史却是模型自己刚写出的块：

$$q_{\text{train}}(B_{<i}) = p_{\text{data}}(B_{<i}), \qquad q_{\text{infer}}(B_{<i}) = p_\theta(B_{<i}).$$

Bengio 等的 scheduled sampling [2]、Ranzato 等的序列级训练 [3]、Self Forcing [19]，处理的都是这个缺口。真要在「只有过去」下训又贵又不稳。缺口还在就再加一级，先让模型自己往下滚，在这段历史上做 DMD [28]，再把同样的损失加到已经带误差的更长历史上，$\mathcal{L}_{\text{long}} = \sum_k \mathcal{L}_{\text{DMD}}^{(k)}$。预训练从没在「只有过去」下训练过，这些阶段都是事后加上的。

写出下一步仍要积一段微分方程，所以要蒸馏。Diffusion Forcing [17]、CausVid [18]、Self Forcing [19]、Rolling Forcing [20]、MAGI-1 [21] 推理时都不看未来，块里面却还是用多步把 K 压下来，整段生成要跑 $N_{\text{blocks}} \times K$ 次前向，到了 $K = 4$ 网络拟合的仍是 $v_\theta(x, \sigma)$。

训练条件没改，每一步仍是多步积分。生成又要比训练窗口更长，于是改的是推理时看得见的过去 $\mathcal{H}_i$：留几帧早期的当锚点、只留最近几块、窗口往前滑时重置位置编码。StreamingLLM [13] 在语言里说过，滑动窗口需要锚点；FramePack [26]、WorldMem [27] 问的是 $\mathcal{H}_i$ 里该留什么。这只改了测试时能看见哪些帧，训练时拟合的条件没动。

现在通行的做法，是缺一层补一层：

现在通行

```
for i in 1..N:
    x ~ N(0, I)
    for σ in [1.0, 0.75, 0.50, 0.25]:
        x = x + Δσ · v_θ(x, σ | B_<i, x)
    cache.write(x)
```

原生

```
for t in 1..T:
    v_t = f_θ(v_<t, c_≤t)
    cache.write(v_t)
```

预训练	双向 DiT，整段短片	学的是 q_bi，不是 p(v_t | v_<t)。
因果	块因果 mask，干净历史	推理时挡住训练用过的未来；历史仍是数据。
短程	自己滚出来的历史 + DMD	补 K，也补 teacher forcing；历史仍短。
长程	拼接 + 固定窗口	

	补长度。训练条件还是没变。
搜索	**窗口多长、要不要重置位置** 改的是 H_i，不是模型参数。

每一级都多一组要调的量，如果预训练从来没用过 $v_{>t}$，下一步也只需一次前向，这些级就没有必要。

块该切多长，不能随便定：一块只有一帧，块里没有前后运动，多步积分只剩空间去噪；一块接近一秒，又变回带边界缓存的短片模型；三帧既能边写边出，又给块内双向去噪留了空间，所以成了常见折中。原生模型得在预训练就定下这个单元，可以一帧跑一次网络，也可以一块跑一次网络，不用额外让三帧共用一个 mask 再积分一遍。

过去的经验

我们过去训过现在这套扩散自回归，Flash [1] 是其中之一，闭环长程生成时，两件事反复出现。

后训练如果优化的是块内去噪，同一块 B_i 里可以更好看，但不一定能改善块与块之间的条件，而 $\prod_t p(v_t \mid v_{<t})$ 要的正是这个。只改 $\mathcal{H}_i$，改的是测试时能看见哪些帧，训练时拟合的条件没动。

	块内观感	跨块一致性
更晚的后训练	**同一块里更干净**	没有稳定跟着变好
只改推理窗口 / 重置	—	没有稳定跟着变好

更晚的后训练，采样和窗口都没动，同一块里纹理更干净，跨块一致性却没有稳定跟着变好。

生成器不动，只改 $\mathcal{H}_i$，加长推理窗口，或者打开、关掉位置和位姿编码的重置，训练条件都没变。窗口和训练对不上，问题出在块与块的接缝；重置和训练对不上，相对位置编码会指向另一套几何。跨块一致性没有因此稳定变好，变的仍是测试时能看见哪些帧，并没有拟合 $p(v_t \mid v_{<t})$。

对原生设计意味着什么

块内后训练，推理时改窗口、开关重置，都到不了拟合 $p(v_t \mid v_{<t})$ 的目标。如果预训练就要拟合 $p(v_t \mid v_{<t}, c_{\le t})$，下一步也只需一次前向，后面几件事其实已经定了。

块内后训练补不上跨块条件。 块内损失会把容量用在 B_i 好不好看上，要把 $\prod_t p(v_t \mid v_{<t})$ 学到，预训练的条件就得是过去，再加一个更好看的蒸馏阶段也补不上这个条件。继续预训练已经双向的 DiT，初始化可以留，但时间上的未来必须从第一步起就看不见。更干净的做法是隐空间不变，帧内仍双向，时间 mask 从随机初始化就是因果的。VideoGPT [7] 写过「下一帧只看过去」，离散码本偏弱，缺的是用现在的 DiT 和视频 VAE 再走这条路 [12] [15] [16]。损失可以还是流匹配，改的是条件：

$$\mathcal{L} = \mathbb{E}_{t,\sigma} \left\| v_\theta(x_{\sigma,t}, \sigma \mid v_{<t}, c_{\le t}) - (\varepsilon - v_t) \right\|_2^2,$$

σ 只加在当前单元上，梯度不经过 $v_{>t}$。少步一致性训练如果想当 $K = 1$ 的手段，得一开始就在 q_{AR} 下训，先学 q_{bi} 再压步数，容量又会用在块内积分上。后训练擅长的正是这个，跨块一致性却没有跟着上来，自己滚一段再加 DMD 还可以继续补，但那是上一节写过的后训练，不是原生模型。

加长窗口、开关重置，改的不是训练条件。 只改 $\mathcal{H}_i$、不改训练条件，跨块一致性没有稳定变好，所以在原生模型里，看得见的过去要成为模型的一部分：要么就是 $v_{<t}$（因果注意力的缓存），要么是参数里对 $v_{<t}$ 的压缩，而且这段历史要接得上梯度。固定「留多少锚点、留多少最近帧」，再去搜要不要重置位置编码，是改造 q_{bi} 时才会去做的事。FramePack [26]、WorldMem [27] 问的是这段历史里该留什么，答案不该是再搜一轮和训练对不齐的窗口。

时间单元在预训练定下来，测试时不再对块内积分。 块内去噪可以更好看，网络却还在算 K 步向量场，如果一块或一帧就是一步，测试时就不能再对这块做 K 步积分。一次网络计算写一帧，最接近语言里的一个词；一次网络计算写 $L > 1$ 帧，块内可以双向，每次写出的片段更长。两种都可以，但 L 不能再当推理超参，改 L 就是改这一步有多长，块长如果还留给测试时折中，就会回到三帧加一段微分方程，后训练会再去优化这段方程。

评价要看跨块，不能只看块内好不好看。 块内更好看，并不等于跨块更一致，只看短片段和块内指标来停训，还会把这两件事当成一回事。用同一套权重，生成时只需一次前向，从第一秒量到超过训练窗口，c_t 中途变了，再看条件是不是仍只依赖 $v_{<t}$。几秒的短片上双向模型更好看并不奇怪，那段长度上训练本来就看得见未来，短片上的观感说明不了原生这条路通不通。

数据也要按「过去已经发生」来切。 等长短片把未来帧也当特征用。q_{AR} 要求数据里的过去也是当时已经发生的：更长的连续镜头、带时间戳的 c_t、中途才出现的条件。不改训练条件，跨块一致性上不来，只改 $\mathcal{H}_i$ 的时候我们见过这件事。

还有几个问题没有答案，最好在再调窗口之前先想清楚。已经双向的大规模视频骨干，只做时间因果的继续预训练，要多久才能去掉 q_{bi} 留下的习惯，要不要重新初始化？连续隐空间上 $K = 1$ 稳不稳，还是需要更强的离散或混合码本？原生目标下，一帧跑一次网络和三帧跑一次网络，哪一个更能同时顾上运动和延迟？学出来的 $\mathcal{H}_i$ 要不要直接用跨块一致性来监督？没有这条监督的窗口搜索，并不改变模型学到的条件。

2021 年离开 VideoGPT「下一帧只看过去」这条路，当时说得通，因为要的是短片段，短片段上 q_{bi} 就是对的模型。现在面对的已经是流式生成，先训双向短片，再做后训练，再在推理时搜 $\mathcal{H}_i$，到不了拟合 $p(v_t \mid v_{<t})$ 的目标，接下来只能在预训练改训练时能看见的变量。没改之前，现在叫「自回归视频」的做法仍是先按整段短片去噪，再在推理时改成只看过去。

结论

原生自回归是两件事，预训练拟合 $p(v_t \mid v_{<t}, c_{\le t})$，写出下一步只需一次前向，现在通行的做法这两条都不成立。事后再补也补不上，块内损失只让同一块更好看，加长窗口或开关重置只改测试时能看见哪些帧，都到不了拟合 $p(v_t \mid v_{<t})$ 的目标。

语言模型这几年走得快，是因为预训练从一开始就在做下一词预测，扩大模型和数据仍在优化同一个目标。视频生成在 2021 年为了短片画质离开了「下一帧只看过去」这条路，后来才加上因果 mask、少步去噪和窗口搜索，让双向短片模型能够流式生成，但这些都没有改变预训练拟合的条件。原生模型必须在预训练时看不见未来，生成下一步也只需一次前向，事后蒸馏补不上这两点。没做到这些，我们离原生自回归视频模型还很远。

参考文献

1. Zhang, S., Li, Y., Zhuang, J., Jin, W., et al. *EchoWM: Open and Enterable Omnimodal World Models.* arXiv:2608.23189, 2026. https://arxiv.org/abs/2608.23189
2. Bengio, S., Vinyals, O., Jaitly, N., and Shazeer, N. *Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks.* NeurIPS, 2015.
3. Ranzato, M., Chopra, S., Auli, M., and Zaremba, W. *Sequence Level Training with Recurrent Neural Networks.* ICLR, 2016. https://arxiv.org/abs/1511.06732
4. van den Oord, A., Kalchbrenner, N., and Kavukcuoglu, K. *Pixel Recurrent Neural Networks.* ICML, 2016. https://arxiv.org/abs/1601.06759
5. Kalchbrenner, N., van den Oord, A., Simonyan, K., et al. *Video Pixel Networks.* 2016. https://arxiv.org/abs/1610.00527
6. Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.* NAACL, 2019.
7. Yan, W., Zhang, Y., Abbeel, P., and Srinivas, A. *VideoGPT: Video Generation using VQ-VAE and Transformers.* 2021. https://arxiv.org/abs/2104.10157
8. Chang, H., Zhang, H., Jiang, L., Liu, C., and Freeman, W. T. *MaskGIT: Masked Generative Image Transformer.* CVPR, 2022. https://arxiv.org/abs/2202.04200

9. Ge, S., Hayes, T., Yang, H., et al. *Long Video Generation with Time-Agnostic VQGAN and Time-Sensitive Transformer.* ECCV, 2022. https://arxiv.org/abs/2204.03638
10. Villegas, R., Babaeizadeh, M., Kindermans, P.-J., et al. *Phenaki: Variable Length Video Generation from Open Domain Textual Descriptions.* 2022. https://arxiv.org/abs/2210.02399
11. Yu, L., Cheng, Y., Sohn, K., et al. *MAGVIT: Masked Generative Video Transformer.* ICLR, 2023. https://arxiv.org/abs/2212.05199
12. Peebles, W., and Xie, S. *Scalable Diffusion Models with Transformers.* ICCV, 2023. https://arxiv.org/abs/2212.09748
13. Xiao, G., Tian, Y., Chen, B., Han, S., and Lewis, M. *Efficient Streaming Language Models with Attention Sinks.* ICLR, 2024. https://arxiv.org/abs/2309.17453
14. OpenAI. *Video generation models as world simulators (Sora).* 2024. https://openai.com/index/video-generation-models-as-world-simulators/
15. HaCohen, Y., Chiprut, N., Brazowski, B., et al. *LTX-Video: Realtime Video Latent Diffusion.* 2024. https://arxiv.org/abs/2501.00103
    Lightricks. *LTX-2 / LTX-2.3.* 2025–2026.
16. Wan Team. *Wan: Open and Advanced Large-Scale Video Generative Models.* 2025. https://arxiv.org/abs/2503.20314
17. Chen, B., Martí Monsó, D., Du, Y., et al. *Diffusion Forcing: Next-token Prediction Meets Full-Sequence Diffusion.* 2024. https://arxiv.org/abs/2407.01392
18. Yin, T., Zhang, Q., Zhang, R., Freeman, W. T., Durand, F., Shechtman, E., and Huang, X. *From Slow Bidirectional to Fast Autoregressive Video Diffusion Models (CausVid).* 2024. https://arxiv.org/abs/2412.07772
19. Huang, X., Li, Z., He, G., Zhou, M., and Shechtman, E. *Self Forcing: Bridging the Train-Test Gap in Autoregressive Video Diffusion.* NeurIPS, 2025. https://arxiv.org/abs/2506.08009
20. Liu, K., Hu, W., Xu, J., Shan, Y., and Lu, S. *Rolling Forcing: Autoregressive Long Video Diffusion in Real Time.* 2025. https://arxiv.org/abs/2509.25161
21. Teng, H., Jia, H., Sun, L., et al. *MAGI-1: Autoregressive Video Generation at Scale.* Sand AI, 2025. https://arxiv.org/abs/2505.13211
22. Bruce, J., Dennis, M., Edwards, A., et al. *Genie: Generative Interactive Environments.* ICML, 2024. https://arxiv.org/abs/2402.15391
23. NVIDIA. *Cosmos World Foundation Model Platform for Physical AI.* 2025. https://arxiv.org/abs/2501.03575
24. Gao, Z., Wang, Q., Zhu, J., et al. *Infinite Worlds with Versatile Interactions (LingBot-World 2.0).* 2026. https://arxiv.org/abs/2607.07534
25. Zhu, H., Liu, H., Zhao, Y., et al. *SANA-WM: Efficient Minute-Scale World Modeling with Hybrid Linear Diffusion Transformer.* 2026. https://arxiv.org/abs/2605.15178
26. Zhang, L. *Packing Input Frame Context in Next-Frame Prediction Models (FramePack).* 2025. https://github.com/lllyasviel/FramePack
27. Xiao, Z., Lan, Y., Zhou, Y., Ouyang, W., Yang, S., Zeng, Y., and Pan, X. *WorldMem: Long-term Consistent World Simulation with Memory.* NeurIPS, 2025. https://arxiv.org/abs/2504.12369
28. Yin, T., Gharbi, M., Zhang, R., Shechtman, E., Durand, F., Freeman, W. T., and Park, T. *One-step Diffusion with Distribution Matching Distillation.* CVPR, 2024. https://arxiv.org/abs/2311.18828

引用

```
@misc{jin2026nativear,
  author       = {Jin, Weiyang},
  title        = {How Far Are We from a Native Autoregressive Video Model?},
  year         = {2026},
  month        = aug,
  institution  = {The University of Hong Kong},
  howpublished = {Blog post},
  url          = {https://waynejin0918.github.io/how-far-native-ar-video/},
}
```

版式参考了 Thinking Machines Lab 的研究笔记，谨此致谢。